

Universidad de Costa Rica

INGENIERÍA ELÉCTRICA



INTELIGENCIA ARTIFICIAL APLICADA A LA INGENIERÍA

Proyecto: Predicción de cancelación de vuelos

Autor:
Cristhian Rojas Álvarez

Carnet: C16760

Julio 2026

1. Introducción

El transporte aéreo depende de la coordinación entre aerolíneas, aeropuertos, condiciones climáticas y horarios programados. De modo que, cuando alguno de estos elementos presenta problemas, o sea un vuelo puede salir tarde o ser cancelado, lo que afecta a los pasajeros, a las conexiones entre aeropuertos y a la planificación operativa de las aerolíneas. Por esta razón, predecir con anticipación el posible estado de un vuelo puede ser útil para apoyar la toma de decisiones, mejorar la comunicación con los usuarios y detectar condiciones que aumentan el riesgo de atrasos o cancelaciones.

Este proyecto consiste en desarrollar un sistema de clasificación multiclase para predecir el estado operativo de vuelos comerciales en Estados Unidos. El sistema asigna cada vuelo a una de tres categorías: puntual, retrasado o cancelado. Para este proyecto, se considera retrasado un vuelo cuya salida presenta más de quince minutos de demora, mientras que los vuelos cancelados se identifican mediante el registro oficial de cancelación incluido en los datos de operación aérea [6].

Para desarrollar la solución se utilizó una arquitectura de datos tipo Medallion en Databricks, organizada en las capas Bronze, Silver y Gold [1]. Esta estructura permitió almacenar los archivos originales, limpiar y estandarizar los datos, integrar información meteorológica e implementar variables útiles para el entrenamiento de modelos de aprendizaje automático. Finalmente, se compararon varios modelos de clasificación, incluyendo Regresión Logística, Random Forest, LightGBM y una red neuronal tipo Multi-Layer Perceptron, con el fin de identificar la alternativa con mejor desempeño.




Figura 1: Arquitectura del pipeline de procesamiento y modelado utilizado en el proyecto.

2. Objetivos

2.1. Objetivo general

Desarrollar un sistema de predicción para clasificar vuelos comerciales de Estados Unidos como puntuales, retrasados o cancelados, utilizando datos operacionales, variables temporales, condiciones meteorológicas y métricas de congestión aeroportuaria mediante una arquitectura de procesamiento de datos en Databricks.

2.2. Objetivos específicos

- Obtener y organizar registros históricos de vuelos comerciales de Estados Unidos para el período comprendido entre enero de 2025 y marzo de 2026.
- Limpiar, validar y estandarizar los datos de vuelos mediante un proceso de transformación desde la capa Bronze hasta la capa Silver.
- Integrar información meteorológica histórica asociada con los aeropuertos de origen de los vuelos para enriquecer el análisis.
- Construir una tabla Gold con variables temporales, climáticas, operacionales y de congestión aeroportuaria que pueda ser utilizada por modelos de aprendizaje automático.
- Entrenar y comparar distintos modelos de clasificación multiclase para identificar el modelo con mejor capacidad de predicción.
- Analizar el desempeño de los modelos mediante métricas como accuracy, precision, recall y F1-score para las clases puntual, retrasado y cancelado.

3. Metodología y desarrollo del pipeline

3.1. Adquisición de datos de vuelos

La información principal del proyecto fue obtenida desde el portal del *Bureau of Transportation Statistics* de Estados Unidos, específicamente en la sección relacionada con el desempeño de vuelos comerciales [6]. Esta fuente contiene registros históricos de operaciones aéreas, incluyendo información sobre fechas, aerolíneas, aeropuertos, horarios programados, horarios reales, retrasos, cancelaciones y causas de demora.

En lugar de descargar todas las columnas disponibles en la plataforma, se realizó una selección previa de las variables necesarias para el objetivo del proyecto. Esta decisión permitió reducir el tamaño de los archivos descargados y concentrar el análisis en los campos que aportaban información útil para la predicción del estado de los vuelos. Los datos se descargaron en archivos mensuales comprimidos en formato ZIP, cubriendo desde enero de 2025 hasta marzo de 2026.

Las columnas seleccionadas se pueden agrupar en varias categorías. Primero se incluyeron variables de fecha, como YEAR, MONTH, DAY_OF_MONTH, DAY_OF_WEEK y FL_DATE, las cuales permiten

identificar patrones por mes, día de la semana y temporada del año. También se descargaron los campos `OP_UNIQUE_CARRIER` y `OP_CARRIER_FL_NUM`, relacionados con la aerolínea operadora y el número de vuelo, ya que diferentes aerolíneas pueden presentar comportamientos operativos distintos.

Además, se incorporaron las variables de origen y destino, incluyendo los identificadores y códigos de aeropuerto: `ORIGIN_AIRPORT_ID`, `ORIGIN`, `DEST_AIRPORT_ID` y `DEST`. Estas columnas son importantes porque permiten relacionar cada vuelo con la ubicación de salida y llegada, así como con las condiciones meteorológicas y el volumen de operaciones en cada aeropuerto.

Para representar la planificación y el resultado de cada operación se utilizaron las variables `CRS_DEP_TIME`, `DEP_TIME`, `DEP_DELAY`, `CRS_ARR_TIME`, `ARR_DELAY`, `CANCELLED`, `CANCELLATION_CODE`, `CRS_ELAPSED_TIME` y `DISTANCE`. Los horarios programados y la duración estimada del vuelo se utilizaron para generar variables operacionales antes de entrenar los modelos, mientras que los valores reales de retraso y cancelación se emplearon para construir la variable objetivo del problema.

Finalmente, se incluyeron las columnas `CARRIER_DELAY`, `WEATHER_DELAY`, `NAS_DELAY`, `SECURITY_DELAY` y `LATE_AIRCRAFT_DELAY`, las cuales describen causas de retrasos reportadas en los registros. Estas variables se conservaron durante la fase de limpieza y auditoría para comprender mejor la estructura de los datos, pero no se utilizaron como variables predictoras finales, debido a que representan información conocida después de que ocurre el vuelo y podrían generar fuga de información durante el entrenamiento.

3.2. Organización inicial de los archivos

Los archivos mensuales descargados fueron almacenados dentro de la carpeta `Dataset` del proyecto, donde cada archivo representa un mes de operaciones aéreas y mantiene una nomenclatura que permite identificar fácilmente el período correspondiente, por ejemplo, `flights_2025_01.zip`, `flights_2025_02.zip` y `flights_2026_03.zip`.

Posteriormente, los archivos comprimidos se cargaron en un volumen de Databricks asociado con la capa Bronze. En esta etapa se conservaron los datos en su formato original, ya que la función principal de Bronze es almacenar la información cruda antes de aplicar transformaciones [1]. Los archivos ZIP fueron descomprimidos dentro del mismo entorno para obtener los archivos CSV que posteriormente serían procesados mediante Apache Spark [8].

Esta organización permitió mantener separados los datos originales, los notebooks de procesamiento y los documentos del proyecto. Además, facilita la reproducibilidad del trabajo, porque los archivos fuente se encuentran agrupados por período y pueden volver a utilizarse si es necesario repetir alguna etapa del pipeline.

3.3. Estandarización de datos en la capa Silver

Después de cargar los archivos CSV, se realizó una inspección inicial para verificar los nombres exactos de las columnas y confirmar que coincidieran con el esquema seleccionado durante la descarga. Para evitar errores causados por valores vacíos, formatos inconsistentes o interpretaciones automáticas incorrectas, los archivos se leyeron inicialmente como texto. Esto permitió conservar el contenido original de cada campo y aplicar conversiones de tipo de manera controlada.

Una vez realizada la lectura, las columnas fueron convertidas a los tipos de datos apropiados. Las variables como año, mes, día, identificadores de aeropuerto y horarios programados se transformaron a valores numéricos enteros, mientras que las distancias, retrasos, duración estimada y causas de demora se convirtieron a valores decimales. También se generó una columna de fecha denominada `FlightDate`, la cual facilita el análisis cronológico y el posterior cruce con los datos meteorológicos.

Durante esta etapa se aplicó una validación de calidad para identificar registros que presentaran valores faltantes en campos esenciales. Se consideraron críticos los datos relacionados con año, mes, fecha de vuelo, aeropuertos de origen y destino, estado de cancelación y distancia del vuelo, de modo que, los registros que no cumplieran con estos criterios fueron enviados a una tabla de rechazados para mantener trazabilidad, mientras que los vuelos válidos continuaron dentro del flujo de procesamiento.

También se eliminaron duplicados a nivel de fila para evitar que una misma operación fuera considerada más de una vez en el entrenamiento. Luego de completar estas transformaciones, los datos limpios fueron almacenados como tablas Delta dentro de la capa Silver. La tabla principal, denominada `silver_vuelos_cancelaciones`, contiene los vuelos válidos y tipados que se utilizaron posteriormente para integrar el clima, generar características y construir la tabla final de entrenamiento.

La estandarización realizada en Silver fue necesaria para convertir una colección de archivos mensuales crudos en una fuente confiable para el análisis, donde gracias a este proceso, los datos quedaron organizados, con tipos consistentes, registros inválidos separados y una estructura adecuada para continuar con las etapas de enriquecimiento meteorológico, ingeniería de características y modelado predictivo.

3.4. Integración de información meteorológica

Después de limpiar los datos de vuelos y guardarlos en la capa Silver, se agregó información meteorológica para darle más contexto al proyecto. La idea era que el modelo no analizara solamente datos como la fecha, la aerolínea, la ruta o la hora programada, sino que también pudiera considerar las condiciones climáticas que existían cerca del aeropuerto de salida. Variables como la lluvia, la nieve, el viento y la temperatura pueden afectar directamente la operación de los vuelos, por lo que incluirlas ayuda a entender mejor por qué algunos vuelos se retrasan o se cancelan.

Primero se identificaron los aeropuertos únicos que aparecían como origen en los registros de vuelos. De cada uno se conservaron el identificador del aeropuerto y su código IATA, que corresponde a las tres letras utilizadas normalmente para reconocerlos, como `JFK`, `LAX` u `ORD`. También se compararon los aeropuertos de origen con los de destino para comprobar que los aeropuertos que recibían vuelos también aparecieran en algún momento como aeropuertos de salida. Esto permitió trabajar con una sola lista de aeropuertos para obtener sus coordenadas y consultar su información meteorológica.

Para conocer la ubicación de cada aeropuerto se utilizó el catálogo de OpenFlights [2]. Este catálogo contiene información de aeropuertos de distintos países, incluyendo el código IATA, la latitud y la longitud. Se filtraron únicamente los aeropuertos ubicados en Estados Unidos y luego se realizó un cruce con los códigos de aeropuerto presentes en los datos de vuelos. Con este proceso

se logró asociar los aeropuertos utilizados en el proyecto con sus coordenadas geográficas reales.

La información obtenida se guardó en la tabla `silver_aeropuertos_coordenadas`. Esta tabla quedó separada de los vuelos porque funciona como un catálogo de apoyo y puede reutilizarse en diferentes etapas del proyecto. De esta forma, no fue necesario volver a procesar el archivo de OpenFlights cada vez que se necesitara conocer la ubicación de un aeropuerto.

Una vez disponibles las coordenadas, se utilizó la API histórica de Open-Meteo para consultar el clima de cada aeropuerto durante el período analizado [3], se descargaron los datos diarios de temperatura máxima, temperatura mínima, precipitación, nieve acumulada y velocidad máxima del viento. Estas variables fueron seleccionadas porque representan condiciones que pueden afectar la salida de un vuelo, especialmente en días con lluvias fuertes, nevadas, vientos elevados o cambios importantes de temperatura.

Para mantener una estructura ordenada, se creó un calendario con todas las fechas del período de estudio para cada aeropuerto. Así, aunque algún aeropuerto no tuviera información climática disponible en una fecha determinada, el registro se mantenía dentro de la tabla con valores nulos. Esto fue útil porque permitió identificar claramente los faltantes y aplicar una estrategia de recuperación más adelante durante la creación de la capa Gold, en lugar de eliminar datos sin revisarlos primero.

Finalmente, los datos meteorológicos fueron transformados con Spark y almacenados en la tabla `silver_clima_historico`, y además de las variables climáticas, se generó una columna de fecha llamada `WeatherDate`, junto con las columnas de año y mes, lo que facilitó el cruce posterior con los vuelos. La tabla se particionó por año y mes para mejorar la organización y el rendimiento al consultar los datos.

Con esta integración, cada vuelo pudo relacionarse con las condiciones meteorológicas de su aeropuerto de origen en la fecha programada, lo que permitió construir un dataset más completo para las siguientes etapas, donde se combinaron las variables de vuelos, clima, tiempo y congestión aeroportuaria antes de entrenar los modelos de predicción.

3.5. Construcción de la capa Gold e ingeniería de características

Después de contar con los vuelos limpios y la información meteorológica organizada en la capa Silver, se construyó la capa Gold. Esta etapa tuvo como propósito crear un único conjunto de datos listo para ser utilizado por los modelos de aprendizaje automático. Para lograrlo, se combinaron las variables originales de los vuelos con los datos del clima y se generaron nuevas características relacionadas con el tiempo, la congestión aeroportuaria y las condiciones operativas de cada vuelo.

El primer paso consistió en unir los vuelos con la información meteorológica disponible, de modo que el cruce se realizó utilizando la fecha del vuelo y el código del aeropuerto de origen, de forma que cada registro pudiera incorporar las condiciones climáticas correspondientes a su día de salida. Sin embargo, algunos aeropuertos no contaban con datos meteorológicos completos, por lo que no era posible asociarlos directamente con una estación climática disponible.

Para resolver este problema se utilizó un árbol de búsqueda espacial llamado `KDTree` [9]. A partir de las coordenadas de latitud y longitud de los aeropuertos esta estructura permitió identificar cuál aeropuerto con datos climáticos se encontraba más cerca de cada aeropuerto sin información, luego, el clima del aeropuerto vecino se utilizó como referencia para completar los vuelos que no podían

relacionarse de manera directa con los datos de Open-Meteo. Aunque esta solución no reemplaza una estación meteorológica exacta para cada aeropuerto, permitió conservar una mayor cantidad de vuelos dentro del análisis y reducir la pérdida de información.

Después de realizar el cruce principal, todavía existían algunos valores climáticos faltantes en fechas específicas. Para estos casos se aplicó una estrategia de imputación temporal. Primero se buscó el último dato climático válido registrado anteriormente para el mismo aeropuerto y se utilizó como referencia para completar el valor faltante, no obstante, cuando no fue posible encontrar un dato anterior, se consultó el valor disponible en una fecha posterior. Entonces, es que este proceso permitió recuperar la mayoría de los registros sin eliminar vuelos de forma innecesaria, mientras que las pocas filas que continuaron con datos climáticos incompletos fueron retiradas antes de generar la tabla final.

Una vez que los datos quedaron completos, se crearon variables temporales para que los modelos pudieran identificar patrones asociados con la fecha y la hora del vuelo. En lugar de utilizar únicamente el número del mes, el día de la semana o la hora programada, estas variables se transformaron mediante funciones seno y coseno. Y es de este modo que, el modelo puede comprender que diciembre y enero están próximos dentro del ciclo anual, o que las 23:00 y las 00:00 representan horas cercanas aunque sus valores numéricos sean muy distintos [10].

También se generaron variables climáticas escaladas, la temperatura máxima, la temperatura mínima, la precipitación, la nieve y la velocidad del viento fueron convertidas a valores comparables en un rango aproximado entre cero y uno, y así se evitaba que una variable con valores grandes, como la precipitación acumulada o la velocidad del viento, tuviese una influencia desproporcionada solamente por su escala numérica. El escalado fue especialmente útil para los modelos que dependen de la magnitud de las variables, como la red neuronal.

Además de las variables de clima y calendario, se incorporaron características relacionadas con la congestión de los aeropuertos. Para ello se contó la cantidad de vuelos programados en cada aeropuerto de origen durante un mismo bloque horario y fecha. De manera similar, se calculó el volumen de llegadas programadas en cada aeropuerto de destino. Estas variables representan una aproximación al nivel de actividad de los aeropuertos, ya que una mayor concentración de vuelos durante una hora determinada puede aumentar la posibilidad de retrasos debido a tráfico aéreo, disponibilidad de puertas, uso de pistas etc.

Los valores de congestión fueron suavizados mediante una transformación logarítmica y luego escalados para evitar que los aeropuertos más grandes domnaran los resultados. Así, el modelo puede comparar de una manera más equilibrada el nivel de actividad de distintos aeropuertos, desde terminales con pocas operaciones hasta aeropuertos con una gran cantidad de vuelos programados durante el día.

Finalmente, se construyó la variable objetivo del proyecto, donde los vuelos cancelados se asignaron a la clase 2, los vuelos con un retraso de salida superior a quince minutos se asignaron a la clase 1 y los demás vuelos se consideraron puntuales, correspondientes a la clase 0. Esta clasificación permitió transformar el problema en una tarea de predicción multiclase, donde los modelos deben decidir cuál de los tres posibles estados es el más probable para cada vuelo.

El resultado de esta etapa fue almacenado en la tabla `gold_vuelos_features`. Nótese, que en esta tabla se reúnen las variables temporales, meteorológicas, operacionales y de congestión junto con la etiqueta final de cada vuelo, y a partir de este dataset se realizó la preparación de datos

para Machine Learning y posteriormente el entrenamiento de los modelos de clasificación.

4. Modelos de clasificación

Una vez construida la tabla `gold_vuelos_features`, se prepararon los datos para entrenar los modelos de clasificación, que si bien la tabla Gold ya contenía las variables principales del proyecto, fue necesario revisar nuevamente los valores nulos, los rangos de las variables escaladas y la consistencia de la etiqueta final antes de llevar los datos a los algoritmos de Machine Learning, de modo que al hacer esta revisión se pudo asegurar que las variables climáticas, temporales y de congestión se encontraran en rangos adecuados y que no existieran valores que pudieran causar errores durante el entrenamiento.

Es importante destacar, que el problema planteado corresponde a una clasificación multiclase, ya que cada vuelo puede pertenecer a una de tres categorías: puntual, retrasado o cancelado. Debido a que en los datos reales los vuelos puntuales son mucho más frecuentes que los retrasados y cancelados, se decidió construir una muestra balanceada para el entrenamiento, y para ello, seleccionaron 150 000 vuelos de cada clase, obteniendo un conjunto de 450 000 registros y con esta decisión se pudo permitir que los modelos aprendieran patrones de las tres categorías sin quedar dominados por los vuelos puntuales.

Continuando, los datos se dividieron en dos grupos mediante una partición estratificada, donde el 80 % de los registros se utilizó para entrenar los modelos y el 20 % restante se reservó para realizar la evaluación final, de modo que al mantener la misma proporción de clases en ambos grupos, fue posible comparar los resultados de forma más equilibrada y verificar si los modelos podían generalizar sobre vuelos que no habían sido utilizados durante el entrenamiento [7].

Además de las variables creadas en la capa Gold, se generaron algunas características adicionales. Se identificaron horarios de mayor actividad, como las horas de la mañana y de la tarde y se calcularon interacciones entre las condiciones meteorológicas y el volumen de vuelos en los aeropuertos, también se incorporó la aerolínea mediante codificación numérica y se utilizaron tasas históricas suavizadas de retraso y cancelación para rutas y aerolíneas, y gracias a ello, estas tasas pudieron representar el comportamiento histórico de una ruta sin usar directamente los nombres de origen y destino como texto dentro de los modelos.

4.1. Regresión Logística

La regresión logística se utilizó como modelo base para tener una referencia sencilla frente a los demás algoritmos. En sí, este modelo busca encontrar una relación entre las variables de entrada y cada una de las clases posibles, por lo que es útil para determinar si los patrones del problema pueden explicarse mediante relaciones relativamente lineales [4].

En este caso se utilizó una versión multiclase, capaz de diferenciar entre vuelos puntuales, retrasados y cancelados, y aunque, la regresión logística es más fácil de interpretar que otros modelos, tiene limitaciones cuando las relaciones entre las variables son complejas. Por ejemplo, la combinación entre una hora de alta congestión, una aerolínea específica y condiciones de lluvia puede afectar un vuelo de una forma que no sigue una relación lineal simple.

Por esta razón, el modelo se incluyó principalmente como un punto de comparación, al punto que el resultado permitió comprobar que el problema requiere algoritmos capaces de representar interacciones más complejas entre las variables climáticas, temporales y operacionales.

4.2. Random Forest

Ahora bien, el modelo random forest se utilizó como una alternativa basada en árboles de decisión, ya que este algoritmo crea una gran cantidad de árboles independientes y combina sus resultados para obtener una predicción final [11]. Nótese, que cada árbol analiza diferentes combinaciones de variables, por lo que el modelo puede capturar relaciones no lineales entre características como la distancia, el horario de salida, el clima, la congestión y la aerolínea.

Una de las ventajas de random forest es que no requiere que las relaciones entre las variables sean lineales, también es que es un modelo resistente al ruido y permite trabajar bien con conjuntos de datos tabulares. En relación con ello, es importante hacer mención que se cuenta con un riesgo de sobreajuste, y para evitarlo se limitaron aspectos como la profundidad máxima de los árboles y la cantidad mínima de registros necesarios para crear divisiones internas.

Entonces, es que el modelo fue entrenado utilizando múltiples árboles y todos los núcleos disponibles del entorno de ejecución para posteriormente evaluarlo tanto con los datos de entrenamiento como con los datos de prueba, y pues esta comparación fue importante porque permitió observar si el modelo aprendía patrones generales o si estaba memorizando demasiado los datos utilizados durante el entrenamiento.

4.3. LightGBM

LightGBM fue utilizado como el modelo principal del proyecto debido a su buen desempeño en problemas de clasificación con datos tabulares. A diferencia de random forest, donde los árboles se crean de manera independiente, LightGBM construye los árboles de forma secuencial, donde cada nuevo árbol busca corregir los errores cometidos por los árboles anteriores, lo que permite mejorar progresivamente la capacidad de clasificación [5].

Este modelo fue configurado para trabajar con las tres clases del proyecto y se aplicaron mecanismos de regularización para reducir el riesgo de sobreajuste, también se utilizó una partición interna de validación durante el entrenamiento, con el objetivo de monitorear el desempeño del modelo y detener el proceso si dejaba de mostrar mejoras importantes.

LightGBM fue especialmente adecuado para aprovechar las variables creadas durante la ingeniería de características. Las tasas históricas de retraso y cancelación, la aerolínea, la congestión por bloque horario y las interacciones entre clima y tráfico presentan relaciones que pueden ser difíciles de capturar con un modelo lineal, entonces por medio de árboles secuenciales, LightGBM pudo identificar combinaciones de estas variables y utilizarlas para mejorar la predicción final.

4.4. Red neuronal Multi Layer Perceptron

También se entrenó una red neuronal tipo multi layer perceptron, conocida como MLP. Este modelo está formado por varias capas de neuronas artificiales que reciben las variables de entrada

y aprenden patrones mediante un proceso de ajuste de pesos. Su principal ventaja es que puede representar relaciones complejas entre las variables, incluso cuando estas no son fáciles de describir mediante reglas simples [12].

Antes de entrenar la red neuronal, se aplicó una estandarización de las variables numéricas, y este paso fue necesario porque algunas variables como la distancia del vuelo o la duración programada, manejaban valores mucho mayores que las variables climáticas escaladas. Entonces, si estandarizar los datos, se evita que las variables con valores más grandes tengan una influencia excesiva sobre el proceso de entrenamiento.

La red utilizada contó con varias capas ocultas y aplicó un mecanismo de detención temprana, esto básicamente significa que el entrenamiento podía finalizar antes de completar todas las iteraciones programadas si el modelo dejaba de mejorar sobre los datos de validación. Con esta estrategia se buscó controlar el sobreajuste y obtener un modelo con una capacidad de generalización más estable.

4.5. Comparación de los modelos

La comparación entre los cuatro modelos permitió analizar el problema desde enfoques diferentes. La regresión logística funcionó como una referencia simple, mientras que random forest y LightGBM permitieron capturar relaciones no lineales por medio de árboles de decisión. Por otro lado, la red neuronal MLP representó una alternativa basada en aprendizaje profundo con capacidad para encontrar patrones complejos en los datos.

Cada modelo fue evaluado con las mismas métricas de clasificación: accuracy, precision, recall y F1-score. La exactitud permitió observar el porcentaje general de predicciones correctas, mientras que precision, recall y F1-score ayudaron a analizar el comportamiento del modelo para cada clase. Estas últimas métricas fueron especialmente importantes porque el objetivo no era solamente identificar vuelos puntuales, sino también detectar correctamente los vuelos retrasados y cancelados [7].

Los resultados obtenidos por cada modelo se presentan en la siguiente sección, donde se analiza cuál algoritmo logró el mejor desempeño general y cuáles clases fueron más fáciles o más difíciles de predecir.

5. Resultados y evaluación de los modelos

Una vez entrenados los modelos, se evaluó su desempeño utilizando el conjunto de prueba reservado durante la preparación de los datos. Este conjunto estuvo formado por 90 000 vuelos, con 30 000 registros de cada clase: vuelos puntuales, vuelos retrasados y vuelos cancelados. Y como se mencionó antes, al trabajar con la misma cantidad de registros por clase, fue posible comparar los modelos de una manera más equilibrada, sin que los vuelos puntuales dominaran los resultados por ser más frecuentes en los datos reales.

Para evaluar cada algoritmo se utilizaron las métricas de accuracy, precision, recall y F1-score. La métrica de accuracy muestra el porcentaje general de predicciones correctas, mientras que precision indica qué tan confiables fueron las predicciones de una clase determinada, por su parte,

el recall permite conocer cuántos casos reales de una clase fueron detectados correctamente y el F1-score combina precision y recall en una sola medida. Estas métricas son importantes porque el proyecto no busca solamente acertar vuelos puntuales, sino también identificar vuelos retrasados y cancelados.

5.1. Comparación general entre modelos

El cuadro 1 presenta los resultados generales obtenidos por cada uno de los modelos entrenados.

Cuadro 1: Comparación general de desempeño de los modelos sobre el conjunto de prueba.

Modelo	Accuracy	Macro F1-score
Regresión Logística	0.48	0.48
Random Forest	0.63	0.63
Red neuronal MLP	0.63	0.63
LightGBM	0.64	0.64




Figura 2: Comparación de la exactitud obtenida por los modelos evaluados.

La Regresión Logística obtuvo el resultado más bajo, con una exactitud de 48 %. Este resultado muestra que las relaciones entre las variables del proyecto no pueden explicarse fácilmente mediante un modelo lineal, por el hecho de que el comportamiento de un vuelo depende de combinaciones entre clima, congestión, hora programada, aerolínea, ruta y otras condiciones, por lo que se requiere un modelo que pueda identificar relaciones más complejas.

Random forest y la red neuronal MLP alcanzaron una exactitud de 63 %, lo que representa una mejora importante con respecto al modelo lineal. Ambos modelos lograron aprender patrones útiles

dentro de los datos, aunque presentaron algunas diferencias en su comportamiento por clase. Y como dato curioso, el random forest mostró un rendimiento alto durante el entrenamiento, pero su resultado disminuyó al evaluar vuelos nuevos, lo cual indica que el modelo pudo haber aprendido algunos patrones demasiado específicos del conjunto de entrenamiento.

Ahora bien, LightGBM obtuvo el mejor resultado general con 64 % de accuracy y un Macro F1-score de 0.64, que aunque la diferencia con Random Forest y MLP no fue muy grande, este presentó un desempeño más equilibrado entre las tres clases. Los resultados detallados de este modelo se presentan en la siguiente subsección.

5.2. Resultados del modelo LightGBM

El cuadro 2 muestra el desempeño detallado de LightGBM para cada una de las clases del problema.

Cuadro 2: Resultados por clase del modelo LightGBM.

Clase	Precision	Recall	F1-score
Puntual	0.62	0.58	0.60
Retrasado	0.54	0.59	0.56
Cancelado	0.77	0.76	0.76




Figura 3: Matriz de confusión del modelo LightGBM sobre el conjunto de prueba.




Figura 4: F1-score del modelo LightGBM para cada clase del conjunto de prueba.

La Figura 3 permite observar con mayor detalle los aciertos y errores del modelo. La mayor cantidad de clasificaciones correctas se presentó en los vuelos cancelados, con 22 700 casos identificados correctamente de un total de 30 000. En cambio, la principal confusión ocurrió entre los vuelos puntuales y retrasados, ya que 10 117 vuelos puntuales fueron clasificados como retrasados, mientras que 8 064 vuelos retrasados fueron clasificados como puntuales. Esto confirma que distinguir entre un vuelo que saldrá a tiempo y uno que tendrá una demora sigue siendo la parte más difícil del problema.

Ahora bien, la clase con mejor resultado fue la de vuelos cancelados. El modelo obtuvo un F1-score de 0.76, con valores de precision y recall cercanos a 0.77 y 0.76, respectivamente. Esto significa que LightGBM logró identificar una parte importante de los vuelos que realmente fueron cancelados y, al mismo tiempo, mantuvo una buena confiabilidad en sus predicciones. Este comportamiento puede estar relacionado con la presencia de señales más claras en este tipo de eventos, como condiciones climáticas complicadas, ciertos períodos del año, congestión aeroportuaria y patrones asociados con algunas aerolíneas o rutas.

Los vuelos retrasados representaron la clase más difícil de predecir. Aunque el modelo alcanzó un recall de 0.59, lo que indica que logró detectar más de la mitad de los retrasos reales, su precision fue de 0.54. Esto significa que parte de los vuelos señalados como retrasados terminaron siendo puntuales o cancelados, en sí este resultado era esperable, ya que muchos retrasos dependen de factores que no están presentes en los datos utilizados, como problemas de mantenimiento, disponibilidad de la tripulación, retrasos de vuelos anteriores, cambios de puerta, decisiones de control aéreo o situaciones operativas de último momento.

En el caso de los vuelos puntuales, el modelo obtuvo un F1-score de 0.60, que aunque esta clase tuvo mejores resultados que la clase retrasada, algunos vuelos puntuales fueron clasificados como retrasados, lo que podría interpretarse como una consecuencia del enfoque del modelo, ya que se

buscó mantener una buena capacidad para detectar riesgos de retraso y no únicamente favorecer la clasificación de vuelos puntuales.

5.3. Análisis del Random Forest

El modelo random forest obtuvo una exactitud de 63 % sobre el conjunto de prueba, sin embargo, al observar su desempeño durante el entrenamiento se encontró una diferencia considerable entre ambos conjuntos, ya que en los datos de entrenamiento, el modelo alcanzó una exactitud cercana a 84 %, mientras que en los datos de prueba su resultado disminuyó a 63 %. Claramente, esta diferencia indica que el random forest aprendió muy bien los patrones presentes en los vuelos utilizados para entrenar, pero tuvo más dificultad al enfrentarse a registros que no había visto antes. En otras palabras, el modelo presentó señales de sobreajuste, aun así, su resultado en prueba fue aceptable y permitió confirmar que los árboles de decisión son capaces de capturar relaciones importantes entre las variables creadas durante el proyecto.

5.4. Análisis de la red neuronal MLP

La red neuronal MLP también alcanzó una exactitud de 63 % y su mejor desempeño se observó en la clase de vuelos cancelados, donde obtuvo un F1-score de 0.76, sin embargo, presentó más dificultad para reconocer los vuelos retrasados con un F1-score de 0.51.

La red fue entrenada después de estandarizar las variables numéricas, ya que este tipo de modelo es sensible a diferencias grandes de escala entre datos como distancia, duración programada y variables climáticas, pero a pesar de que logró resultados similares que al random forest, su tiempo de entrenamiento fue mayor y no superó el desempeño general de LightGBM. Por esta razón, se considera como un modelo complementario dentro de la comparación, pero no como la alternativa principal para una posible implementación futura.

6. Discusión de resultados

Los resultados muestran que las variables construidas durante el proyecto aportan información útil para estimar el estado de un vuelo. La combinación entre fecha, horario programado, aerolínea, distancia, clima y congestión permitió identificar patrones que un modelo lineal como la regresión logística no logró representar con la misma precisión. Por esta razón, LightGBM fue seleccionado como el modelo final, ya que pudo aprovechar mejor las relaciones no lineales entre estas variables.

Las cancelaciones fueron el estado más fácil de reconocer, probablemente porque suelen estar relacionadas con señales más visibles dentro de los datos, como condiciones climáticas adversas, temporadas específicas, alta actividad en los aeropuertos o patrones de ciertas rutas y aerolíneas. En cambio, los retrasos fueron más difíciles de predecir, pues muchos pueden depender de situaciones que no estaban incluidas en el dataset, por ejemplo, mantenimiento de la aeronave, disponibilidad de tripulación, retrasos en vuelos anteriores o decisiones operativas tomadas poco antes de la salida.

Por lo tanto, el modelo no debe interpretarse como una herramienta que conoce con certeza lo que ocurrirá con un vuelo. Su utilidad está en identificar señales de riesgo antes de la salida progra-

mada, de modo que podría servir como base para generar alertas tempranas, apoyar el seguimiento de vuelos o informar a los pasajeros sobre una mayor posibilidad de retraso o cancelación.

7. Limitaciones y trabajo futuro

Aunque el modelo logró resultados útiles, existen factores que no pudieron incluirse dentro del análisis, ya que la información climática utilizada corresponde a datos históricos diarios, por lo que no representa exactamente las condiciones presentes en la hora de salida de cada vuelo. Además de que, para completar algunos faltantes se emplearon datos de fechas cercanas, por lo que el sistema debe interpretarse como una especie de evaluación y no como un pronóstico operativo disponible en tiempo real. También faltan variables como retrasos del vuelo anterior, disponibilidad de tripulación, mantenimiento de aeronaves o cambios de puerta, las cuales pueden influir especialmente en los retrasos.

También debe considerarse que los modelos fueron entrenados con una muestra balanceada de vuelos puntuales, retrasados y cancelados. Esta decisión permitió que las tres clases tuvieran la misma importancia durante el entrenamiento, pero no representa la distribución real de los vuelos comerciales, donde la mayoría suele salir de forma puntual.

Como trabajo futuro, sería conveniente utilizar información climática por hora o pronósticos disponibles antes de la salida del vuelo, asimismo, se podría realizar una división temporal de los datos, entrenando con vuelos de 2025 y evaluando con vuelos de 2026, para simular de mejor manera una situación real. Finalmente, el modelo podría integrarse en un dashboard que permita consultar el riesgo de retraso o cancelación de un vuelo según su fecha, ruta, aerolínea y horario programado.

8. Conclusiones

El proyecto permitió construir un flujo completo de datos para analizar y predecir el estado de vuelos comerciales en Estados Unidos. A partir de los archivos originales se aplicó una arquitectura Bronze, Silver y Gold, donde los datos fueron limpiados, estandarizados y enriquecidos con información meteorológica antes de utilizarlos en los modelos de Machine Learning.

La integración de variables como fecha, hora programada, aerolínea, distancia, clima y congestión aeroportuaria permitió crear un dataset más completo que los registros originales de vuelos. Esto hizo posible clasificar cada vuelo como puntual, retrasado o cancelado, utilizando una muestra balanceada para que las tres clases pudieran ser aprendidas por los modelos.

Se entrenaron cuatro modelos de clasificación: regresión logística, random forest, LightGBM y una red neuronal MLP. LightGBM obtuvo el mejor resultado general, con una exactitud de 64 % y un Macro F1-score de 0.64. Además, presentó un buen desempeño al identificar vuelos cancelados, con un F1-score de 0.76.

Los resultados muestran que el proyecto puede servir como base para estimar riesgos de retraso o cancelación antes de la salida de un vuelo. Aunque todavía existen variables operativas que no fueron incluidas, el trabajo demuestra cómo la ingeniería de datos, Apache Spark y los modelos

de clasificación pueden combinarse para resolver un problema real relacionado con el transporte aéreo.

Referencias

- [1] Databricks. (s. f.). *What is medallion architecture?* Recuperado el 29 de junio de 2026, de <https://www.databricks.com/blog/what-is-medallion-architecture>
- [2] OpenFlights. (s. f.). *OpenFlights.org: Flight logging, mapping, stats and sharing.* Recuperado el 29 de junio de 2026, de <https://openflights.org/>
- [3] Open-Meteo. (s. f.). *Free weather API.* Recuperado el 29 de junio de 2026, de <https://open-meteo.com/>
- [4] scikit-learn developers. (s. f.). *scikit-learn: Machine learning in Python.* Recuperado el 29 de junio de 2026, de <https://scikit-learn.org/stable/>
- [5] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc. https://papers.nips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf
- [6] Bureau of Transportation Statistics. (s. f.). *On-time reporting carrier on-time performance (1987–present): Download data.* U.S. Department of Transportation. Recuperado el 12 de junio de 2026, de https://www.transtats.bts.gov/DL_SelectFields.aspx?gnoyr_VQ=FGJ&Q0_fu146_anzr=b0-gvzr
- [7] Coto Jiménez, M. (2026). *Introducción a los modelos clásicos de inteligencia artificial aplicada a la ingeniería eléctrica* [Notas de clase, IE-0456]. Universidad de Costa Rica.
- [8] Apache Software Foundation. *Apache Spark: Lightning-fast unified analytics engine.* <https://spark.apache.org/>
- [9] Bentley, J. L. (1975). *Multidimensional binary search trees used for associative searching.* Communications of the ACM, 18(9), 509–517. <https://doi.org/10.1145/361002.361007>
- [10] scikit-learn developers. (s. f.). *Time-related feature engineering.* Recuperado el [30 de Junio de 2026], de https://scikit-learn.org/stable/auto_examples/applications/plot_cyclical_feature_engineering.html
- [11] Breiman, L. (2001). *Random Forests.* Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [12] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning.* MIT Press. <https://www.deeplearningbook.org/>

- [13] Anusha, D., Yasmin, S., Karishma, S., Kumar, K. P., & Rajini, P. (2024). Flight delay prediction based on aviation big data and machine learning. *International Journal of Engineering Science and Advanced Technology*, 24(5), 33–40. https://ijesat.com/ijesat/files/V24I0505_1714814325.pdf